

트랜스포머 기반 한국어 대화 모델의 모드 붕괴 및 텍스트 생성 오류 극복에 관한 연구
(A Study on Overcoming Mode Collapse and Text Generation Errors in
Transformer-based Korean Chit-chat Models)

하지양
Ji-lyang ha
gwd7454@gmail.com

초록 (Abstract)

본 연구는 Transformer 기반의 Sequence-to-Sequence 구조를 활용하여 한국어 일상 대화 챗봇을 처음부터 학습(Training from scratch)시키는 과정에서 발생하는 생성 오류를 분석하고 이를 해결하는 통합적 파이프라인을 제안한다. 제한된 데이터셋에서 훈련된 대화 모델은 "저랑 이야기해 주는 게 좋을 것 같아요"와 같은 만능 답변(Generic Response)에 과적합되는 모드 붕괴(Mode Collapse) 현상을 보였다. 이를 해결하기 위해 모델의 수용력(Capacity)을 조정하는 구조적 정규화를 수행하였으나, 추론 과정에서 N-gram 무한 반복(Degeneration) 및 단어 샐러드(Word Salad) 현상이 추가로 발생하였다. 본 연구는 누적 확률 기반의 Top-p (Nucleus) 샘플링과 동적 글로벌 페널티(Dynamic Global Repetition Penalty)를 결합하여 반복 루프를 억제하였으며, 타겟(Target) 데이터의 무결성을 보존하는 비대칭적 데이터 증강(Asymmetric Augmentation) 파이프라인을 구축하여 생성된 텍스트의 유창성(Fluency)을 개선하고자 하였으나, 한계가 있음을 확인하였다

Abstract

This study proposes an integrated pipeline to analyze and resolve text generation errors that occur when training a Transformer-based Sequence-to-Sequence Korean chit-chat model from scratch. Trained on a limited dataset, the dialogue model exhibited mode collapse, overfitting to generic responses such as "I think it would be best to talk with me." To address this, we applied structural regularization to adjust the model's capacity; however, this subsequently led to N-gram degeneration (infinite repetition) and word salad phenomena during inference. To mitigate these issues, we suppressed the repetition loops by combining cumulative probability-based Top-p (Nucleus) sampling with a dynamic global repetition penalty. Furthermore, by constructing an asymmetric data augmentation pipeline that preserves the integrity of the target data, we dramatically improved the fluency and contextual relevance of the generated text.

1 서론

Introduction

인공지능 기반의 개방형 대화(Open-domain Chat-chat) 시스템은 사용자의 다양한 입력에 대해 자연스럽게 문맥에 맞는 응답을 생성하는 것을 목표로 한다. **신경망 기반 대화 모델(A Neural Conversational Model)의 가능성을 제시한 연구 [1]** 이후, 어텐션(Attention) 메커니즘을 핵심으로 하는 트랜스포머(Transformer) 구조를 제안한 논문 [2]가 등장하면서 자연어 생성(NLG) 성능은 비약적으로 향상되었다. 그러나 대규모 사전 학습(Pre-training) 모델을 사용하지 않고, 제한된 코퍼스로 모델을 밑바닥부터 훈련(Training from scratch)할 경우 시스템은 여전히 여러 구조적 및 알고리즘적 한계에 부딪힌다.

첫째, 대화 모델의 '**모드 붕괴(Mode Collapse)**' 및 '**보편적 응답(Generic Response)**' 편향 문제이다. 신경망 대화 모델의 다양성 증진 목적 함수(Diversity-Promoting Objective Function)에 관한 연구 [3]에서 지적되었듯, 전통적인 최대 우도 추정(Maximum Likelihood Estimation, MLE) 방식으로 훈련된 Seq2Seq 모델은 손실(Loss)을 최소화하기 위해 "모르겠어요", "저랑 이야기해요"와 같이 정보량이 적고 안전한 만능 답변만을 생성하려는 경향이 있다. 이는 제한된 데이터셋에서 모델의 수용력(Capacity)이 과도할 때 발생하는 심층적인 과적합(Overfitting)의 일환이다.

둘째, 텍스트 생성 과정에서 발생하는 '**기계적 반복(Degeneration)**' 현상이다. 비우도 학습(Unlikelihood Training)을 통한 자연어 생성 모델의 단어 반복 문제를 지적한 연구 [4]와 신경망 텍스트 열화 현상(Neural Text Degeneration)을 분석한 연구 [5]에 따르면, 탐욕 탐색(Greedy Search)이나 빔 탐색(Beam Search)과 같은 결정론적 디코딩 방식은 확률을 최대화하려는 속성 때문에 동일

한 단어나 N-gram 구(Phrase)를 무한히 반복하는 늪에 빠지기 쉽다.

마지막으로, **데이터 증강(Data Augmentation)에 따른 언어적 훼손**이다. 데이터 부족 현상을 타개하기 위해 텍스트 처리 성능 향상을 위한 데이터 증강 기법(EDA) 연구 [6]에서 제안된 어휘 대체(Lexical Substitution) 등의 기법이 널리 쓰이고 있다. 그러나 이를 한국어와 같은 고도의 교착어(Agglutinative language) 타겟(Target) 데이터에 무분별하게 적용할 경우 조사와 어미의 호응이 파괴되어 명사만 나열되는 '단어 샐러드(Word Salad)' 현상을 유발한다.

따라서 본 연구는 이러한 세 가지 고질적인 텍스트 생성 오류들의 근본 원인을 추적하고, 이를 극복하기 위한 통합적 최적화 방법론을 제안한다. 이를 위해 모델의 구조적 정규화(Regularization)를 통한 모드 붕괴 억제, Top-p (Nucleus) 샘플링 및 동적 페널티 결합을 통한 N-gram 루프 방지, 그리고 비대칭적 데이터 증강(Target-Preserved Augmentation)을 통한 문법적 유창성 확보 방안을 차례로 검증하고자 한다.

2 이론적 배경 및 주요 용어

Background & Terminology

본 연구의 방법론과 실험 결과를 명확히 이해하기 위해, 텍스트 생성 모델에서 흔히 발생하는 주요 오류 현상과 이를 제어하기 위한 핵심 기법을 다음과 같이 정의한다.

모드 붕괴 (Mode Collapse): 생성 모델이 학습 데이터의 다양한 분포(대화의 문맥)를 학습하지 못하고, 훈련 손실(Loss)을 쉽게 회피하기 위해 가장 안전하고 획일적인 단일 결과물(예: 만능 답변)만 반복해서 출력하는 심층적인 과적합(Overfitting) 현상.

단어 샐러드 (Word Salad): 인공지능이 문장의 핵심 키워드는 파악했으나, 조사와 어미 등의 문법적 호응을 잃어버리고 명사 위주의




Figure 1 전체 시스템 아키텍처

파편화된 단어들만 무작위로 나열하는 텍스트 생성 오류. 주로 훈련 데이터의 문법적 무결성이 훼손되었을 때 발생한다.

N-gram 무한 루프 (Degeneration): 텍스트를 한 단어씩 순차적으로 생성하는 자동 회귀(Autoregressive) 모델이 동일한 단어나 구(Phrase)의 늪에 빠져 문장을 종료(EOS 토큰 생성)하지 못하고 기계적으로 무한 반복하는 현상.

Top-p (Nucleus) 샘플링: 추론 시 무조건 확률 1위의 단어만 고르는 탐욕 탐색(Greedy Search)의 한계를 보완하기 위해, 누적 확률이 특정 기준(예: 90%) 안에 드는 상위권 후보 단어들 사이에서만 확률적으로 다음 단어를 선택하여 문장의 다양성과 자연스러움을 동시에 확보하는 디코딩 기법.

3 연구 방법

Methods

본 연구에서는 한국어의 교착어적 특성을 반영하기 위해 mecab기반의 형태소 분석을 적용한 Standard Transformer (Seq2Seq) 모델을 설계하였으며, 제안하는 전체 시스템 아키텍처는 Figure 1과 같다. 생성 오류를 완화하기 위해 다음과 같은 세 가지 접근을 수행하였다.

3.1. 데이터 증강 파이프라인 최적화 (Target-Preserved Augmentation)

초기 모델은 데이터 부족을 해결하기 위해 Word2Vec 기반 어휘 대체(Lexical Substitution)를 적용하였으나, 타겟(Target) 문장의 어휘가 강제 변경될 경우 한국어 특유의 조사와 어미 호응이 파괴되어 명사만 나열되는 단어 샐러드(Word Salad) 오류를 유발했다. 이를 방지하기 위해 Figure 2와 같이 입력 문장(Source)에만 데이터 증강을 수행하고, 정답 문장(Target)은 원본의 문법적 무결성을 유지하는 비대칭적 증강(Asymmetric Augmentation) 파이프라인을 구축하였다.

3.2. 모델 아키텍처 및 하이퍼파라미터 정규화

대화 데이터셋의 분포 내에서 모델의 수용력(Capacity)이 과도할 경우 발생하는 단순 암기 및 모드 붕괴를 억제하기 위해 하이퍼파라미터를 재설계하였다.

구조적 병목 적용: 임베딩 차원과 은닉층의 크기(d_{model})를 512에서 256으로 축소하여 무분별한 암기 공간을 제한하고, 인코더/디코더 깊이(n_{layers})를 4로 늘려 문맥 추론 능력을 강화하였다.




Figure 2 비대칭적 증강(Asymmetric Augmentation) 파이프라인

강력한 정규화: 드롭아웃(Dropout) 비율을 0.4로 상향 조정하여 특정 가중치에 대한 과도한 의존성을 낮췄다.

3.3. 고급 디코딩 전략 (Advanced Decoding Strategy)

매 스텝(Step) 최적 단어 1개만 선택하는 탐욕 탐색(Greedy Search)의 한계를 극복하기 위해 Figure 3의 확률적 샘플링과 페널티 메커니즘을 도입하였다.

$$\hat{z}_t(w) = \frac{\tilde{z}_t(w)}{\tau}$$

Top-p (Nucleus) Sampling: 예측된 Logit 값에 온도 스케일링($\tau=0.7$)을 적용한 후, 누적 확률이 임계값 $p=0.9$ 를 초과하지 않는 상위 단어 집합 내에서만 샘플링을 수행하여 텍스트의 무작위성과 문법성을 조율하였다.

동적 글로벌 반복 페널티 (Dynamic Global Repetition Penalty):

기계적 반복 루프를 원천 차단하기 위해 Figure 4와 같이 과거에 한 번이라도 생성된 적 있는 토큰의 Logit 점수에 강력한 감쇠 페널티를 부여하여, 해당 토큰의 확률을

감소시키는 방식으로 정의된다. 모델이 강제로 새로운 조사와 서술어를 탐색하도록 유도함으로써 N-gram 루프 현상을 원천 차단하였다.

$$\tilde{z}_t(w) = \begin{cases} \frac{z_t(w)}{2.0} - 5.0, & w \in H_t \text{ and } z_t(w) > 0 \\ 2.0 z_t(w) - 5.0, & w \in H_t \text{ and } z_t(w) \leq 0 \\ z_t(w), & w \notin H_t \end{cases}$$

생성 시점 t 에서 각 토큰 w 의 원래 로짓을 $z_t(w)$ 라 하고, 이전까지 생성된 토큰 집합을 H_t 라 할 때, 반복 페널티가 적용된 로짓 $\tilde{z}_t(w)$ 는 다음과 같이 정의된다.

여기서 H_t 는 이전 시점까지 생성된 토큰들의 중복 없는 집합(set)이다. 즉, 동일 토큰이 여러 번 등장했더라도 페널티는 빈도(count)가 아니라 “한 번이라도 생성된 적 있는가”에 따라 적용된다.

이 방식은 양의 로짓에 대해서는 값을 절반으로 줄인 뒤 추가로 5.0을 감산하고, 음의 로짓에 대해서는 절댓값이 더 커지도록 두 배로 확대한 뒤 다시 5.0을 감산한다. 결과적으로 이미 생성된 토큰은 다음 시점에서 다시 선택될 확률이 크게 낮아진다.




Figure 3 확률적 샘플링과 페널티 메커니즘 도입




Figure 4 글로벌 반복 억제 메커니즘(Global Repetition Penalty)

이러한 방식은 특정 토큰이 반복적으로 선택 되는 현상을 효과적으로 억제하며, 모델이 새로운 단어를 탐색하도록 유도한다.

3.4. 데이터셋 상세 (Dataset Description)

본 연구에서는 한국어 일상 대화 생성을 위해 총 약 11,764개의 질의응답(Q-A) 쌍으로 구성된 대화 데이터셋을 사용하였다. 데이터는 공개된 한국어 대화 코퍼스 및 자체 수집 데이터를 결합하여 구성하였으며, 데이터의 품질을 유지하기 위해 중복 제거 및 비문 필터링을 수행하였다.

전체 데이터셋은 학습(train), 검증(validation), 테스트(test) 세트로 8:1:1 비

율로 분할하였다. 각 문장의 평균 길이는 약 10.2 토큰이다.

본 연구에서는 SentencePiece 기반 Subword 토큰화 대신, Mecab 기반 형태소 분석을 활용한 lexical_sub_mecab 토큰나 이저를 사용하였다. 해당 방식은 한국어의 교착어적 특성을 반영하여 조사와 어미를 분리된 형태소 단위로 처리함으로써, 문법적 구조를 보다 명확하게 학습할 수 있도록 한다

형태소 단위 토큰나이징을 적용함으로써, "연락해볼까"와 같은 복합 표현을 ["연락", "하", "아", "보", "니까"]와 같이 분해하여 모델이 문법적 조합을 학습할 수 있도록 하였

다.

본 연구에서는 최대 vocabulary 크기를 10,000으로 설정하였으나, 실제 vocabulary 크기는 토큰나이저 학습 과정에서 특수 토큰 (BOS, EOS, PAD, UNK) 및 데이터 분포에 따라 결정되어 최종적으로 10,000개로 구성되었다.

3.5. Length Distribution Analysis




Figure 6 토큰화된 문장의 길이 분포

Figure 6는 토큰화 이후 데이터셋의 문장 길이 분포를 나타낸다.

분포는 우측으로 긴 꼬리를 가지는 형태 (right-skewed)를 보이며, 대부분의 문장은 5~20 토큰 범위에 집중되어 있다. 반면 일부 문장은 40 토큰 이상의 긴 시퀀스로 구성되어 긴 꼬리(long tail)를 형성한다.

이러한 분포는 대화 데이터의 특성을 반영하며, 대부분의 발화는 짧고 간결한 반면 일부는 복잡한 구조를 가지는 것을 의미한다.

본 연구에서는 이러한 특성을 기반으로 전체 데이터의 95% 이상을 포함할 수 있는 최대 시퀀스 길이 25를 설정하여, 불필요한 패딩을 최소화하면서도 긴 문맥 정보를 유지하도록 하였다.

또한 평균 문장 길이가 상대적으로 짧은 분포를 보이므로, 과도한 모델 용량보다는 경량화된 Transformer 구조(d_model=256)를 사용하는 것이 적절하다고 판단하였다.

4 실험 및 결과

Results

4.1. 모델 학습 및 수렴 (Training Convergence)




Figure 7 Epoch에 따른 Training Loss(실선 -)와 BLEU Score(점선 --) 변화.

총 35 epoch 동안 학습을 수행한 결과, Figure 7과 같이 training loss는 약 80 수준에서 시작하여 최종적으로 약 44 수준까지 점진적으로 감소하며 안정적인 수렴 양상을 보였다. 특히 loss는 초기 구간에서 급격히 감소한 이후, 중반 이후에는 완만한 감소 곡선을 형성하며 안정적으로 수렴하는 패턴을 나타냈다. 이는 모델이 학습 초기에 빠르게 데이터의 주요 패턴을 학습한 후, 점진적으로 미세 조정을 수행하고 있음을 의미한다. 한편, BLEU score는 초기에는 낮고 불안정한 값을 보였으나 epoch이 증가함에 따라 전반적으로 상승하는 경향을 나타냈다. 이와 같은 결과는 제안된 Custom Learning Rate Schedule과 Dropout(0.4)이 모델의 학습을 안정적으로 유도하면서 과적합을 효과적으로 억제했음을 보여준다. 또한 loss 감소와 BLEU score 증가가 동시에 관찰된다는 점에서, 모델이 단순한 손실 최소화를 넘어 실제 생성 품질 또한 점진적으로 향상시키고 있음을 확인할 수 있다. 이에 추가적으로 epoch을 더 늘려 관찰 해보는 실험이 필요할 것으로 보인다.

입력 문장 (Source)	기존 오류 (Greedy / Word Salad)	최종 결과 (정규화 + Top-p + Target-Preserved)	정답 문장 (Ground Truth)
학교쌤 좋아하는 사람 있나 ?	저랑 이야기해 주는 게 좋을 것 같아요	마음가 꾸준히 부모님 것 하나 더 사랑할 생각 그래요	존경의 의미라고 생각해보는 건 어떨까요.
학교에 씬남 있는데 연락해볼까 ?	연락 생각 감기 큰 쉽길 바랍니다	연락 생각 감기 큰 쉽길 바랍니다	용기를 내서 먼저 연락해 보는 것도 좋을 것 같아요.
가상화폐 쫄딱 망함	저랑 이야기해도 저랑 이야기해도...	어서 어디 오는 하루 더 거예요	어서 잊고 훌훌 털어버리세요.

Table 1 ; 제안된 디코딩 알고리즘 적용 후 최종 모델 생성 결과

4.2. 모드 붕괴(Mode Collapse) 및 과소적합 해결

초기 베이스라인 모델은 "학교쌤 좋아하는 사람 있나?", "가상화폐 쫄딱 망함" 등 다양한 질문에 대해 오직 "저랑 이야기해 주는 게 좋을 것 같아요"라는 만능 답변만 출력하는 심각한 모드 붕괴를 보였다.

d_model 축소 및 드롭아웃 증가 등 구조적 정규화를 거치고 Epoch를 최적화한 결과, 입력 문장의 핵심 키워드 ("연락", "망함", "사랑" 등)를 기반으로 정상적인 Cross-Attention이 작동함을 확인하였다.

4.3. 디코딩 제어를 통한 N-gram 무한 루프 억제

하이퍼파라미터 정규화 이후에도 추론 과정에서 "그렇 마음 그럴 마음...", "두 두 두..."와 같이 생성 루프에 빠지는 현상이 나타났다. 이에 Top-p 샘플링과 글로벌 반복 페널티를 적용한 결과, 기계적인 단어 반복이 억제되었으며 모델이 스스로 적절한 위치에서 <EOS>(End Of Sentence) 토큰을 예측하여 유한한 길이의 문장을 성공적으로 생성하였다.

4.4. 타겟 데이터 보존 학습을 통한 단어 샐러드 현상의 완화 및 한계

디코딩 최적화 후에도 관찰된 '단어 샐러드' 오류("연락 생각 감기 큰 쉽길 바랍니다")는 타겟 데이터 원본 보존(Target-Preserved) 학습을 통해 유의미하게 감소되었으나 완전히 해소되지는 않았다.

4.5 제안된 디코딩 알고리즘 적용 후 최종 모델 생성 결과

디코딩 알고리즘 적용 후 모델의 최종 생성 결과는 Table 1과 같다. 모델은 "썸남", "연락해볼까"라는 입력에 대해 "연락", "생각" 등의 키워드를 출력하고, "사랑해"라는 입력에 "사랑", "분위기" 등의 연관 단어를 출력함으로써 Cross-Attention 메커니즘이 입력 문장의 문맥(Semantics)을 정상적으로 맵핑하고 있음을 증명하였다. 그러나 생성된 단어들 사이의 문법적 결속력이 현저히 떨어지며, 조사와 어미가 생략된 채 명사 위주로 나열되는 '단어 샐러드(Word Salad)' 현상이 뚜렷하게 관찰되었다. 이는 모델이 핵심 의미를 파악하는 데는 성공했으나, 한국어 특유의 복잡한 교착어적 문법 규칙을 소규모 훈련 데이터만으로 완벽히 일반화

(Generalization)하지 못했기 때문에 분석된다.

4.6. Evaluation Metrics

본 연구에서는 생성 모델의 성능을 정량적으로 평가하기 위해 다음과 같은 지표를 사용하였다.

(1) **BLEU Score**: 생성된 문장과 정답 문장 간의 n-gram 일치를 기반으로 문맥적 적합성을 평가한다.

(2) **Distinct-N**: 생성 문장의 다양성을 측정하기 위한 지표로, 전체 n-gram 대비 고유 n-gram의 비율로 정의된다.

(3) **Repetition Rate**: 생성된 문장에서 반복되는 n-gram의 비율을 측정하여, N-gram 무한 루프 현상의 억제 정도를 평가한다.

(4) **Grammar Score**: 한국어 문장의 문법적 완성도를 평가하기 위해 조사(Josa) 및 어미(Eomi)의 출현 비율을 기반으로 정의된 지표로, 단어 샐러드 현상의 정량적 측정을 가능하게 한다.

4.7 Quantitative Results

BLEU	Dist-1	Dist-2	Repetition	Grammar
0.029	0.685	0.927	0.000	0.270

Table 2 정량적 평가

제안된 방법의 성능을 정량적으로 평가한 결과는 Table 2와 같다. BLEU score는 0.029로 나타났으며, 이는 제한된 데이터셋 환경에서 학습된 모델이 정답 문장과 완전히 일치하는 표현을 생성하기보다는 의미적으로 유사한 다양한 표현을 생성하는 경향이 있음을 보여준다.

반면 Distinct-1과 Distinct-2는 각각 0.685와 0.927로 높은 값을 기록하여, 생성 문장의 다양성이 충분히 확보되었음을 확인할 수 있다. 이는 기존 모델에서 나타났던 모드 붕괴(mode collapse) 현상이 효과적으로 완화되었음을 의미한다.

특히 Repetition Rate가 0.0으로 나타난 것은 제안된 글로벌 반복 페널티와 Top-p 샘플링이 결합되어 N-gram 반복 문제를 사실상 제거했음을 보여준다.

Grammar Score는 0.270으로 측정되었으며, 이는 형태소 기반 토큰나이징과 타겟 데이터 보존 전략을 통해 문법적 구조가 일정 수준 유지되고 있음을 나타낸다. 다만, 완전한 문장 생성보다는 핵심 의미 전달에 집중된 결과로 해석된다.

5 결론 및 향후 과제

Conclusion and Future Work

본 연구는 Transformer 기반 한국어 대화 챗봇 시스템을 구축하며 겪는 다양한 모델링 이슈들을 성공적으로 해결하였다.

그러나 최종 실험 결과에서 나타난 단어 샐러드 현상은 Sequence-to-Sequence 모델을 소규모 코퍼스만으로 Training from scratch 할 때 발생하는 근본적인 한계점을 여실히 보여준다. 모델은 Cross-Attention을 통해 입력 질문과 관련된 어휘(Vocabulary)를 추출하는 단계까지는 도달하였으나, 이를 한국어의 문법에 맞게 유창한(Fluent) 시퀀스로 조립하는 언어 모델링(Language Modeling) 능력은 부족했다. 또한 초기에 시도된 데이터 증강(Lexical Substitution) 과정에서 훼손된 타겟 문장의 노이즈가 언어 모델의 문법 학습에 치명적인 방해 요소로 작용했을 가능성이 높다.

결론적으로, 본 연구는 제한된 자원 환경에서 디코딩 제어만으로 문맥적 키워드 추출과 생성 제어가 가능함을 입증하는 동시에, 유창한 대화 생성을 위해서는 방대한 텍스트로 문법적 기초가 다져진 대규모 사전 학습 모델(Pre-trained Language Model)에 대한 전이 학습(Transfer Learning)이 필수 불가결하다는 강력한 실증적 근거를 제시한다. 향후 연구에서는 본 파이프라인의 디코딩 전략을 사전 학습 모델에 결합하여 유창성과

다양성을 모두 갖춘 대화 시스템으로 고도화할 계획이다.

6. Acknowledgment

본 연구를 진행함에 있어 아이펠의 기술적 지원과 기여에 감사를 표한다. 또한 PyTorch 및 관련 오픈소스 생태계 커뮤니티의 기술적 지원과 기여에도 감사를 표한다.

7. References

- [1] Vinyals, O., & Le, Q. (2015). A neural conversational model. arXiv preprint arXiv:1506.05869.
- [2] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems*, 30.
- [3] Li, J., Galley, M., Brockett, C., Gao, J., & Dolan, B. (2015). A diversity-promoting objective function for neural conversation models. arXiv preprint arXiv:1510.03055.
- [4] Welleck, S., Kulikov, I., Roller, S., Dinan, E., Cho, K., & Weston, J. (2019). Neural text generation with unlikelihood training. arXiv preprint arXiv:1908.04319.
- [5] Holtzman, A., Buys, J., Du, L., Forbes, M., & Choi, Y. (2019). The curious case of neural text degeneration. arXiv preprint arXiv:1904.09751.
- [6] Wei, J., & Zou, K. (2019). EDA: Easy data augmentation techniques for boosting performance on text classification tasks. arXiv preprint arXiv:1901.11196.